



Beyond Chinchilla’s Ω : A Scaling Law for the Overtraining Factor

Applied to Linguistic Extension of an LLM to Baoulé,
a West African Language

Zousko Nicanor, Angoula Jaurès, Daniel Sossa
Tree IA Labs – Côte d’Ivoire
September 12, 2026

Abstract

La loi de Chinchilla (Hoffmann et al., 2022) fournit un cadre de référence pour dimensionner le volume de tokens nécessaire à l’entraînement d’un grand modèle de langage (LLM) *from scratch*, mais elle ne couvre ni le régime de sur-entraînement pratiqué par les laboratoires modernes, ni les besoins spécifiques du pré-entraînement continu (extension linguistique d’un modèle déjà formé), ni ceux de l’alignement comportemental supervisé (SFT). Nous proposons un cadre en trois contextes – création initiale, extension linguistique continue, alignement SFT – chacun borné par un seuil minimal et un plafond maximal, et nous l’appliquons numériquement à deux architectures (270 millions et 70 milliards de paramètres) dans le cadre d’un projet concret d’extension d’un LLM vers le baoulé. Nous montrons ensuite qu’une des hypothèses du cadre initial – un facteur de sur-entraînement Ω constant, indépendant de la taille du modèle – produit des volumes de tokens irréalistes à grande échelle (au-delà des corpus textuels disponibles), et nous proposons une correction empirique sous forme d’une loi de puissance décroissante $\Omega(N)$, calibrée sur sept modèles publiés (Llama, Gemma, OLMo, Phi-3). Les résultats corrigés réduisent le plafond de sur-entraînement du modèle à 70 milliards de paramètres de plusieurs ordres de grandeur, le ramenant dans une plage compatible avec les corpus existants, tout en préservant la cohérence du cadre pour les petites architectures.

Mots-clés : lois d’échelle, LLM, Chinchilla, pré-entraînement continu, oubli catastrophique, alignement supervisé, extension linguistique, langues à faibles ressources.

1 Introduction

Le dimensionnement du corpus d’entraînement d’un grand modèle de langage (LLM) est une décision structurante : sous-dimensionner le corpus laisse le modèle sous-entraîné, tandis que le sur-dimensionner gaspille un budget de calcul rare, particulièrement critique pour des équipes ne disposant pas des ressources d’un grand laboratoire. La loi de Chinchilla (Hoffmann et al., 2022) a apporté une réponse rigoureuse à cette question pour le cas de l’entraînement *from scratch* : pour un modèle de N paramètres, un volume de $20 \times N$ tokens minimise la perte d’entraînement à budget de calcul fixé. Ce résultat, obtenu à partir de plus de 400 entraînements contrôlés, a corrigé la prescription antérieure de Kaplan et al. (2020), qui sous-estimait fortement l’importance des données par rapport aux paramètres.

Cependant, la loi de Chinchilla répond à une question précise – combien de tokens pour entraîner un modèle sain à partir de zéro, au moindre coût de calcul – qui ne couvre pas trois situations pourtant centrales dans la pratique actuelle du développement de LLM :

- (i) Le **sur-entraînement délibéré** de petits modèles bien au-delà du point Chinchilla, pratiqué par la quasi-totalité des laboratoires pour réduire le coût d’inférence (Section 2) ;
- (ii) Le **pré-entraînement continu** (continual pretraining), qui consiste à injecter une nouvelle compétence – typiquement une nouvelle langue – dans un modèle déjà entraîné, sans repartir de zéro ;
- (iii) L’**alignement comportemental supervisé** (SFT), qui n’ajoute pas de connaissance nouvelle mais apprend au modèle un format de dialogue.

Ce travail s’inscrit dans un contexte plus large où la majorité des langues africaines, y compris des langues parlées par plusieurs millions de locuteurs comme le baoulé en Côte d’Ivoire, restent quasi absentes des corpus d’entraînement des LLM généralistes, faute de textes numérisés en quantité suffisante. Disposer d’un cadre de dimensionnement explicite – même approximatif – est particulièrement utile dans ce contexte : il permet d’évaluer, avant d’engager une collecte de corpus coûteuse en temps humain, si l’objectif visé est atteignable avec les ressources disponibles, et d’arbitrer entre plusieurs tailles d’architecture candidates.

Ce travail part d’un projet concret : l’extension d’un modèle de langage pré-entraîné (en français/anglais) vers le baoulé, une langue à faibles ressources parlée en Côte d’Ivoire, pour deux architectures cibles de tailles très différentes (270 millions et 70 milliards de paramètres). Ce contexte pratique nous a conduits à formuler un cadre en six équations couvrant les trois situations ci-dessus, chacune bornée par un seuil minimal et un plafond maximal. Nous appliquons ensuite ce cadre numériquement, puis nous en examinons la robustesse : nous montrons qu’une hypothèse implicite du cadre initial – un facteur de sur-entraînement constant, indépendant de la taille du modèle – produit des besoins en données incompatibles avec les corpus textuels réellement disponibles dès que N dépasse quelques milliards de paramètres. Nous proposons une correction empirique de cette hypothèse, calibrée sur des modèles publiés, et nous en tirons les conséquences pour le dimensionnement pratique du projet baoulé.

2 Contexte et travaux connexes

2.1 La loi de Chinchilla et le régime de sur-entraînement

Hoffmann et al. (2022) établissent que, pour un budget de calcul fixé, la perte d’entraînement est minimisée lorsque le nombre de paramètres N et le nombre de tokens D croissent à peu près au

même rythme, avec un point d’équilibre proche de $D \approx 20N$. Ce résultat a immédiatement révélé que des modèles antérieurs comme GPT-3 (175 milliards de paramètres, entraîné sur environ 300 milliards de tokens, soit moins de 2 tokens par paramètre) étaient très fortement sous-entraînés au regard de leur taille.

Paradoxalement, les laboratoires n’ont pas cherché à se rapprocher du point Chinchilla mais à s’en éloigner délibérément, dans la direction opposée à celle de GPT-3 : entraîner des modèles plus petits sur beaucoup plus de tokens que ne le prescrit Chinchilla. La raison est économique : le coût de calcul de l’entraînement ne se paie qu’une fois, tandis que le coût d’inférence se paie à chaque requête, potentiellement des milliards de fois sur la durée de vie du modèle (Sardana & Frankle, 2024). Un modèle plus petit coûte moins cher à servir ; il est donc rationnel de dépenser davantage de calcul à l’entraînement (en le nourrissant de plus de tokens) pour obtenir un modèle plus compact à qualité égale.

Les ratios tokens/paramètre observés sur des modèles publiés illustrent l’ampleur de cet écart avec le point Chinchilla (ratio = 20) :

Modèle	Paramètres	Tokens d’entraînement	Ratio tokens/param.
Llama 3.2 1B	1,23 Md	jusqu’à 9 T	≈ 7317
Phi-3-mini	3,8B	3,3 Md	≈ 868
OLMo-7B	7 Md	2,46 T	≈ 351
Llama 3 8B	8 Md	15 T	≈ 1875
Gemma 2 9B	9 Md	8 T	≈ 889
Llama 3 70B	70 Md	15 T	≈ 214
Llama 2 70B	70 Md	2 T	≈ 28

Table 1: Ratios tokens/paramètre observés sur des modèles publiés, tous très supérieurs au point Chinchilla (20), à l’exception notable de Llama 2 70B qui reste proche de ce point. Sources : Touvron et al. (2023a,b); Dubey et al. (2024); Meta AI (2024); Gemma Team (2024a,b); Groeneveld et al. (2024); Abdin et al. (2024).

Deux observations s’imposent à la lecture du Tableau 1. Premièrement, le ratio tend à décroître à mesure que N augmente (7317 pour 1,23 milliard de paramètres contre 214 pour 70 milliards) : plus un modèle est grand, moins il est sur-entraîné en proportion, probablement parce que le gain marginal de qualité par token supplémentaire décroît, et parce que le coût d’entraînement d’un grand modèle sur un nombre disproportionné de tokens devient rapidement prohibitif. Deuxièmement, la dispersion est importante à taille comparable (OLMo-7B : 351 contre Llama 3 8B : 1875, pour des tailles quasi identiques), ce qui traduit des choix de laboratoire différents (budget de calcul disponible, philosophie de conception) plutôt qu’une loi physique unique. Ces deux observations seront le point de départ de la correction proposée en Section 5.

D’un point de vue computationnel, ce phénomène s’explique par la relation approximative entre coût de calcul d’entraînement C (en FLOPs), nombre de paramètres N et nombre de tokens D :

$$C \approx 6ND \quad (1)$$

(Kaplan et al., 2020; Hoffmann et al., 2022). À budget de calcul C fixé, l’équation (1) montre que N et D sont substituables : on peut toujours compenser une réduction de N par une augmentation proportionnelle de D sans changer le coût total d’entraînement. Le choix de sur-entraîner (privilégier un D élevé et un N faible) plutôt que de suivre le point Chinchilla n’est donc pas un choix qui augmente le coût d’entraînement à qualité de modèle égale – il déplace simplement ce coût vers davantage de tokens et moins de paramètres, dans une combinaison qui reste, par construction de

l’équation (1), iso-coût en entraînement, tout en réduisant le coût unitaire d’inférence proportionnellement à N .

2.2 Pré-entraînement continu et oubli catastrophique

Le pré-entraînement continu (continual pretraining, ou continued/continual pre-training, CPT) consiste à poursuivre l’entraînement d’un modèle déjà pré-entraîné sur un nouveau corpus, sans repartir de zéro (Ke et al., 2023). Cette approche est nettement plus économe que le ré-entraînement complet lorsqu’il s’agit d’ajouter une compétence spécifique (domaine, langue) à un modèle qui possède déjà des capacités générales de raisonnement.

Le risque principal du pré-entraînement continu est l’oubli catastrophique (catastrophic forgetting) : les mises à jour de poids nécessaires pour apprendre la nouvelle compétence dégradent les capacités précédemment acquises (Kirkpatrick et al., 2017; Luo et al., 2025). Luo et al. (2025) montrent empiriquement que ce phénomène s’aggrave à mesure que la taille du modèle augmente, sur une plage de 1 à 7 milliards de paramètres. La pratique courante pour limiter ce risque consiste à mélanger, dans le corpus de pré-entraînement continu, une part de données de replay (replay) issues de la distribution originale du modèle, aux côtés des données du nouveau domaine ou de la nouvelle langue – une stratégie documentée notamment sur des modèles spécialisés en géosciences et en mathématiques, avec des ratios de mélange typiquement compris entre 1:1 et 8:1 selon les cas (DACP, 2025; Continual Survey, 2024). Le facteur de plasticité α et le coefficient de tolérance γ introduits en Section 3 formalisent cette même intuition – il existe un volume minimal en-deçà duquel la nouvelle compétence ne s’installe pas, et un plafond au-delà duquel elle écrase les compétences existantes – sans toutefois s’appuyer sur une loi publiée équivalente à celle de Chinchilla pour ce régime spécifique.

2.3 Alignement comportemental et sobriété des données de SFT

Contrairement au pré-entraînement (initial ou continu), le supervised fine-tuning (SFT) n’a pas vocation à enseigner de nouvelles connaissances factuelles ou linguistiques au modèle, mais à lui apprendre un format d’interaction – répondre à une instruction, respecter un style de dialogue. Zhou et al. (2023) démontrent, avec le modèle LIMA (65 milliards de paramètres), qu’un jeu de seulement 1 000 exemples soigneusement sélectionnés suffit à obtenir des performances d’alignement comparables à des modèles entraînés sur des centaines de milliers d’exemples de préférence humaine, ce qui appuie leur hypothèse selon laquelle « la quasi-totalité de la connaissance d’un LLM est acquise pendant le pré-entraînement, et seule une quantité limitée de données d’instruction est nécessaire pour enseigner au modèle un format de sortie de haute qualité ». Les auteurs notent toutefois qu’en dessous de 1 000 exemples la stabilité de l’entraînement se dégrade, et que 2 000 exemples offrent une marge de sécurité. Ce résultat conforte l’ordre de grandeur très faible (par rapport au pré-entraînement) attribué au SFT dans le cadre proposé ici.

3 Cadre théorique proposé

Le cadre distingue trois contextes d’entraînement, correspondant à trois moments distincts du cycle de vie d’un LLM. Chaque contexte est borné par un seuil minimal (en-deçà duquel l’objectif visé – performance générale, nouvelle compétence, ou alignement comportemental – n’est pas atteint) et, lorsque cela est pertinent, un plafond maximal (au-delà duquel un risque spécifique apparaît : coût disproportionné, oubli catastrophique, ou surapprentissage).

3.1 Contexte A : la création initiale (from scratch)

Dans ce contexte, le modèle part de poids aléatoires et doit acquérir syntaxe, logique, code et connaissance du monde.

Seuil minimal (loi de Chinchilla).

$$D_{ch} = 20 \times N \quad (2)$$

où D_{ch} est le nombre de tokens requis pour le pré-entraînement initial et N le nombre de paramètres du modèle (Hoffmann et al., 2022).

Plafond maximal (régime de sur-entraînement).

$$D_{scratch_max} = \Omega \times N, \quad \Omega \in [20\,000, 30\,000] \quad (3)$$

où Ω est le facteur d’over-training moderne. Cette valeur, empruntée à l’ordre de grandeur observé sur les architectures les plus légères (cf. Tableau 1), est traitée dans la formulation initiale comme une constante indépendante de N – une hypothèse dont nous montrons en Section 5 qu’elle doit être révisée.

3.2 Contexte B : l’extension linguistique (pré-entraînement continu)

Dans ce contexte, le modèle possède déjà ses structures logiques ; on cherche à lui injecter une compétence nouvelle – ici, une langue supplémentaire – en réutilisant ses capacités de raisonnement préexistantes.

Seuil minimal (seuil de plasticité linguistique).

$$D_{emp} = \alpha \times D_{ch}, \quad \alpha = 0,10 \quad (4)$$

En substituant l’équation (2) :

$$D_{emp} = 0,10 \times (20 \times N) = 2 \times N \quad (5)$$

Le facteur α (facteur de plasticité linguistique) formalise l’idée qu’une compétence nouvelle greffée sur un modèle déjà formé demande une fraction seulement de la charge nécessaire à un apprentissage complet from scratch, car le modèle réutilise son socle logique existant plutôt que de le reconstruire.

Plafond maximal (limite d’oubli catastrophique).

$$D_{ext_max} = \gamma \times D_{emp}, \quad \gamma = 10 \quad (6)$$

soit, en substituant l’équation (5) :

$$D_{ext_max} = 10 \times (2 \times N) = 20 \times N \quad (7)$$

Le coefficient γ formalise le risque documenté en Section 2.2 : au-delà d’un certain volume de tokens de la nouvelle langue, les nouveaux poids écrasent les anciens et le modèle perd ses facultés logiques initiales au profit d’une hyper-spécialisation linguistique.

3.3 Contexte C : l'alignement comportemental (SFT)

La phase de SFT n'ajoute aucune connaissance brute ; elle apprend au modèle à se comporter comme un assistant (format de dialogue, paires question/réponse).

Seuil minimal.

$$D_{sft_min} = \beta \times D_{emp}, \quad \beta = 0,01 \quad (8)$$

soit, en substituant l'équation (5) :

$$D_{sft_min} = 0,01 \times (2 \times N) = 0,02 \times N \quad (9)$$

Plafond maximal (limite de surapprentissage).

$$D_{sft_max} = \mu \times D_{sft_min}, \quad \mu = 5 \quad (10)$$

soit, en substituant l'équation (9) :

$$D_{sft_max} = 5 \times (0,02 \times N) = 0,10 \times N \quad (11)$$

Dépasser ce plafond revient à forcer le modèle à mémoriser les exemples d'entraînement au lieu de généraliser le format d'interaction – un risque d'autant plus élevé que le modèle est petit et le jeu d'exemples restreint et répétitif.

3.4 Statut épistémique des coefficients

Il importe de distinguer clairement, dans ce cadre, ce qui relève d'un résultat publié et validé statistiquement de ce qui relève d'une hypothèse de travail. Seule l'équation (2) (loi de Chinchilla) s'appuie sur une étude contrôlée à grande échelle. Les coefficients Ω , α , γ , β et μ sont des heuristiques de dimensionnement, choisies par cohérence avec des ordres de grandeur observés dans la littérature citée en Section 2 (sur-entraînement, oubli catastrophique, sobriété du SFT), mais aucun d'entre eux ne provient d'une régression statistique publiée sur un grand nombre de modèles, à l'exception d' Ω que nous recalibrons en Section 5. Ce cadre doit donc être lu comme une grille de dimensionnement raisonnée plutôt que comme une loi d'échelle au sens strict de Chinchilla.

4 Applications numériques initiales

Nous appliquons le cadre des équations (2) à (11) à deux architectures cibles du projet d'extension linguistique vers le baoulé, en conservant provisoirement $\Omega = 20\,000$ constant, avant d'en examiner la validité en Section 5.

4.1 Cas 1 : architecture légère, $N = 270 \times 10^6$

$$D_{ch} = 20 \times 270\,000\,000 = 5\,400\,000\,000 \text{ tokens} \quad (12)$$

$$D_{scratch_max} = 20\,000 \times 270\,000\,000 = 5\,400\,000\,000\,000 \text{ tokens} \quad (13)$$

$$D_{emp} = 2 \times 270\,000\,000 = 540\,000\,000 \text{ tokens} \quad (14)$$

$$D_{ext_max} = 200 \times 270\,000\,000 = 54\,000\,000\,000 \text{ tokens} \quad (15)$$

$$D_{sft_min} = 0,02 \times 270\,000\,000 = 5\,400\,000 \text{ tokens} \quad (16)$$

$$D_{sft_max} = 0,10 \times 270\,000\,000 = 27\,000\,000 \text{ tokens} \quad (17)$$

En appliquant une répartition 70 % baoulé / 30 % français au volume D_{emp} : 378 millions de tokens en baoulé et 162 millions en français. En base de 300 tokens par exemple de dialogue, le SFT correspond à 18 000 exemples (seuil minimal) à 90 000 exemples (plafond).

4.2 Cas 2 : architecture massive, $N = 70 \times 10^9$

$$D_{ch} = 20 \times 70\,000\,000\,000 = 1\,400\,000\,000\,000 \text{ tokens} \quad (18)$$

$$D_{scratch_max} = 20\,000 \times 70\,000\,000\,000 = 1,4 \times 10^{15} \text{ tokens} \quad (19)$$

$$D_{emp} = 2 \times 70\,000\,000\,000 = 140\,000\,000\,000 \text{ tokens} \quad (20)$$

$$D_{ext_max} = 200 \times 70\,000\,000\,000 = 14\,000\,000\,000\,000 \text{ tokens} \quad (21)$$

$$D_{sft_min} = 0,02 \times 70\,000\,000\,000 = 1\,400\,000\,000 \text{ tokens} \quad (22)$$

$$D_{sft_max} = 0,10 \times 70\,000\,000\,000 = 7\,000\,000\,000 \text{ tokens} \quad (23)$$

Répartition 70/30 du volume D_{emp} : 98 milliards de tokens en langue cible, 42 milliards en français. Le SFT correspond, en base de 300 tokens, à environ 4,67 millions (seuil) à 23,33 millions (plafond) d’exemples.

C’est la valeur $D_{scratch_max} = 1,4 \times 10^{15}$ tokens (1,4 quadrillion) du Cas 2 qui constitue le signal d’alerte central de cet article : elle dépasse de deux ordres de grandeur la taille des plus grands corpus textuels publics connus, de l’ordre de 15 à 40 trillions de tokens toutes sources combinées (web filtré, livres, code, données synthétiques). Un plafond théorique qu’aucun corpus existant ne permet d’atteindre n’est pas un plafond opérant ; il signale une hypothèse à corriger plutôt qu’une contrainte réelle du problème.

4.3 Sensibilité au facteur de plasticité α

Le facteur $\alpha = 0,10$ étant une hypothèse de travail (Section 3.4) plutôt qu’une valeur mesurée, il est utile d’examiner comment D_{emp} varierait si cette hypothèse était révisée. Le Tableau 2 présente cette sensibilité pour le Cas 1 ($N = 270$ millions).

Hypothèse sur α	D_{emp} (tokens)	Baoulé (70 %)	Français (30 %)
$\alpha = 0,05$ (prudent)	270 M	189 M	81 M
$\alpha = 0,10$ (retenu)	540 M	378 M	162 M
$\alpha = 0,15$	810 M	567 M	243 M
$\alpha = 0,20$ (généreux)	1,08 Md	756 M	324 M

Table 2: Sensibilité du volume empirique D_{emp} au choix du facteur de plasticité linguistique α , pour $N = 270$ millions de paramètres. La relation étant linéaire ($D_{emp} = 20\alpha N$), doubler α double directement le volume de tokens requis.

Cette linéarité signifie qu’une erreur de calibration sur α se répercute proportionnellement sur l’estimation du besoin en corpus baoulé : une sous-estimation d’un facteur 2 de α (par exemple, la valeur réelle serait 0,20 plutôt que 0,10) conduirait à sous-évaluer de moitié le volume de corpus baoulé nécessaire pour stabiliser la nouvelle langue. C’est un argument supplémentaire, au-delà de celui développé en Section 7, pour traiter α comme une hypothèse à valider empiriquement en cours de projet plutôt que comme une constante figée : un suivi des métriques de compréhension en baoulé à intervalles réguliers de tokens vus (par exemple tous les 50 millions de tokens) permettrait de détecter le point d’inflexion réel et d’ajuster la collecte de corpus en conséquence, plutôt que de s’engager sur la totalité du volume prédit dès le départ.

5 Correction empirique du facteur de sur-entraînement Ω

5.1 Le problème : une constante qui ne tient pas à grande échelle

L’équation (3) traite Ω comme une constante universelle, calibrée sur l’observation que de très petits modèles (de l’ordre de la centaine de millions à quelques milliards de paramètres) peuvent être entraînés à des ratios tokens/paramètre de 10 000 à 30 000 sans saturation apparente des gains de performance (Sardana & Frankle, 2024). Le Tableau 1 (Section 2.1) montre cependant que ce ratio n’est pas stable lorsque N varie : il passe de 7317 pour un modèle de 1,23 milliard de paramètres à 214 pour un modèle de 70 milliards – soit un facteur 34 de différence sur une plage de taille de modèles couramment déployés. Appliquer la même constante $\Omega = 20\,000$ aux deux cas du Cas pratique 2 produit un volume de tokens 65 fois supérieur au plus grand corpus documenté publiquement (15 T pour Llama 3), ce qui est physiquement irréaliste : il n’existe tout simplement pas assez de texte disponible (même en comptant des sources synthétiques) pour atteindre ce plafond à cette échelle de modèle.

5.2 Une correction sous forme de loi de puissance décroissante

Nous proposons de remplacer la constante Ω par une fonction décroissante de N :

$$\Omega(N) = \Omega_0 \times \left(\frac{N_0}{N} \right)^k \quad (24)$$

où N_0 est une taille de modèle de référence, Ω_0 le ratio observé à cette référence, et $k > 0$ un exposant de décroissance. Le plafond de sur-entraînement corrigé devient :

$$D_{scratch_max}(N) = \Omega(N) \times N = \Omega_0 \times N_0^k \times N^{1-k} \quad (25)$$

5.3 Calibration sur des modèles publiés

Nous calibrons Ω_0 et k par régression linéaire en échelle logarithmique ($\log \Omega = \log \Omega_0 + k \log(N_0/N)$) sur les six points de données du Tableau 1 pour lesquels un ratio maximal documenté est disponible (Llama 3.2 1B, Phi-3-mini, OLMo-7B, Llama 3 8B, Gemma 2 9B, Llama 3 70B). Nous excluons Llama 2 70B de la régression : entraîné volontairement près du point Chinchilla, ce point ne relève pas du régime de sur-entraînement modélisé ici et introduirait un biais. La régression donne, avec $N_0 = 270 \times 10^6$ comme référence :

$$\Omega_0 \approx 12\,800, \quad k \approx 0,78 \quad (R^2 \approx 0,68) \quad (26)$$

Le coefficient de détermination modéré ($R^2 \approx 0,68$) reflète honnêtement la dispersion observée entre laboratoires à taille comparable (OLMo-7B : 351 contre Llama 3 8B : 1 875, pour des tailles quasi identiques) : le facteur de sur-entraînement dépend aussi de choix propres à chaque laboratoire (budget de calcul disponible, philosophie de conception, disponibilité de données spécifiques) et pas uniquement de N . La loi de puissance ne doit donc pas être lue comme une loi physique déterministe au sens de Chinchilla, mais comme une tendance centrale documentée, suffisante pour corriger l’ordre de grandeur du plafond et éviter l’écueil identifié en Section 4.2.

5.4 Plafonds corrigés

Le Tableau 3 recalcule $D_{scratch_max}$ pour les deux architectures du projet, avec l’ancienne constante ($\Omega = 20\,000$) et avec la fonction corrigée $\Omega(N)$.




Figure 1: Décroissance en loi de puissance de $\Omega(N)$, calibrée sur les sept modèles publiés du Tableau 1 ($\Omega_0 \approx 12\,800$, $N_0 = 270 \times 10^6$, $k \approx 0,78$). Le ratio tokens/paramètre passe de 167 368 à 10 millions de paramètres à seulement 12 à 2 trillions de paramètres, illustrant la décroissance continue du facteur de sur-entraînement à mesure que N augmente.

Architecture	Ω constant (ancien)	$\Omega(N)$ corrigé	$D_{scratch_max}$ corrigé
270 M paramètres	20 000	$\approx 12\,800$	$\approx 3,47$ T tokens
1 B paramètres	20 000	$\approx 4\,610$	$\approx 4,61$ T tokens
70 B paramètres	20 000	≈ 166	$\approx 11,6$ T tokens

Table 3: Plafonds de sur-entraînement avant et après correction. Le plafond corrigé pour 70 milliards de paramètres (11,6 trillions de tokens) est désormais cohérent avec l’ordre de grandeur des plus grands corpus publiés (15 T pour Llama 3), alors que le plafond non corrigé (1,4 quadrillion) ne l’était pas.

La correction ne modifie pas les équations du Contexte B (extension linguistique) ni du Contexte C (SFT), qui ne dépendent pas d’ Ω : seul le plafond théorique du Contexte A (création from scratch) est concerné. Pour le projet d’extension vers le baoulé, dont l’objectif n’est précisément pas de ré-entraîner from scratch mais d’étendre un modèle existant, cette correction a une portée essentiellement diagnostique : elle confirme que les volumes utilisés en pratique (équations (5) et (7), qui ne dépendent que de N) restent la référence opérationnelle pertinente, et que le plafond $D_{scratch_max}$ ne doit être invoqué que si l’option d’un ré-entraînement complet est un jour envisagée.

5.5 Une tension résiduelle à très grande échelle

La correction proposée en (24) résout le problème identifié en Section 5.1 pour les tailles de modèles considérées dans ce travail (270 millions à 70 milliards de paramètres), mais elle introduit, si on la prolonge au-delà, une seconde tension qu’il convient de signaler par souci de rigueur. Parce que l’exposant $k \approx 0,78$ est proche de 1, le plafond corrigé $D_{scratch_max}(N) = \Omega_0 N_0^k N^{1-k}$ croît




Figure 2: Croissance du plafond corrigé $D_{scratch_max}(N) = \Omega(N) \times N$ sur trois ordres de grandeur (10 M à 2 T paramètres). L’exposant effectif $N^{0.22}$ produit une croissance très lente : le plafond passe de 1,7 T tokens à 10 millions de paramètres à seulement 24,6 T tokens à 2 trillions de paramètres, contre les $1,4 \times 10^{15}$ tokens irréalistes qu’aurait prescrit la constante $\Omega = 20\,000$ à cette échelle.

très lentement avec N (en $N^{0.22}$), alors que le plafond d’extension linguistique $D_{ext_max} = 200N$ (équation (7)) croît linéairement. Les deux courbes se croisent à :

$$N_{\times} = N_0 \left(\frac{\Omega_0}{200} \right)^{1/k} \approx 5,5 \times 10^{10} \text{ paramètres } (\approx 55 \text{ milliards}) \quad (27)$$

Au-delà de ce seuil, le plafond théorique de tokens autorisé pour étendre un modèle existant (Contexte B) dépasserait le plafond de sur-entraînement autorisé pour le créer from scratch (Contexte A, corrigé) – ce qui est incohérent, puisque le pré-entraînement continu ne devrait, par construction, jamais requérir davantage de données que ne pourrait en absorber un entraînement complet du même modèle. Le Cas pratique 2 de cet article (70 milliards de paramètres) se situe précisément à la limite de cette zone de tension (Tableau 3 : $1,16 \times 10^{13}$ contre $1,4 \times 10^{13}$ tokens, soit un écart de moins de 20 %). Ce résultat suggère que le coefficient $\gamma = 10$ (équation (6)), tout comme Ω , mériterait probablement d’être lui-même modélisé comme une fonction décroissante de N plutôt que comme une constante – une piste que nous laissons à des travaux ultérieurs (Section 7) faute de données empiriques suffisantes sur le pré-entraînement continu à très grande échelle pour la calibrer avec la même méthode qu’en Section 5.3.

6 Synthèse chiffrée et discussion

6.1 Tableau de synthèse

Le Tableau 4 rassemble, pour les deux architectures du projet, l’ensemble des seuils et plafonds définis en Section 3, avec le plafond $D_{scratch_max}$ corrigé de la Section 5.




Figure 3: Croisement des deux plafonds théoriques : $D_{scratch_max}$ corrigé (bleu, croissance en $N^{0,22}$) et $D_{ext_max} = 200N$ (orange, croissance linéaire). Les deux courbes se croisent vers $N_{\times} \approx 55$ milliards de paramètres (ligne rouge pointillée, équation (27)) : au-delà de ce seuil, le plafond d’extension linguistique dépasserait le plafond de création from scratch, matérialisant la tension résiduelle discutée en Section 5.5.

6.2 Formule générale directe

Pour le contexte B (extension linguistique), qui est le contexte opérationnel du projet, la combinaison des équations (4) et (2) donne la loi directe :

$$D_{emp} = \alpha \times (20 \times N) = (20\alpha) \times N \quad (28)$$

soit, avec $\alpha = 0,10$:

$$D_{emp} = 2 \times N \quad (29)$$

Cette relation signifie que le volume empirique minimal de tokens pour l’extension linguistique se trouve, par construction des coefficients choisis ($\alpha = 0,10$), égal au double du nombre de paramètres du modèle – une coïncidence arithmétique commode pour la mémorisation de l’ordre de grandeur, mais qui ne doit pas être interprétée comme une nécessité théorique : elle découle uniquement de la valeur choisie pour α , et changerait proportionnellement si cette hypothèse de plasticité linguistique était révisée à la lumière de futures données expérimentales.

6.3 Implications pratiques pour le projet

Trois enseignements se dégagent de cette application numérique pour le dimensionnement concret du corpus baoulé/français :

- (a) Le volume à réunir pour l’architecture légère (378 millions de tokens en baoulé) est un objectif de collecte de corpus réaliste pour une langue à faibles ressources, comparable à

Quantité	270 M paramètres	70 B paramètres
D_{ch} (seuil, from scratch)	5,4 Md tokens	1,4 T tokens
$D_{scratch_max}$ (plafond, corrigé)	3,47 T tokens	11,6 T tokens
D_{emp} (seuil, extension linguistique)	540 M tokens	140 Md tokens
dont langue cible (70 %)	378 M tokens	98 Md tokens
dont français (30 %)	162 M tokens	42 Md tokens
D_{ext_max} (plafond, extension linguistique)	54 Md tokens	14 T tokens
D_{sft_min} (seuil, SFT)	5,4 M tokens (18 000 ex.)	1,4 Md tokens (4,67 M ex.)
D_{sft_max} (plafond, SFT)	27 M tokens (90 000 ex.)	7 Md tokens (23,33 M ex.)

Table 4: Synthèse des seuils et plafonds pour les deux architectures cibles du projet d’extension vers le baoulé. Md = milliards, T = trillions (10^{12}). Base de conversion en exemples de SFT : 300 tokens par paire instruction/réponse.

l’ordre de grandeur des plus grands corpus disponibles pour des langues africaines peu dotées numériquement, alors que le volume correspondant pour l’architecture massive (98 milliards de tokens en baoulé) est vraisemblablement hors de portée avec les ressources actuellement numérisées dans cette langue – ce qui plaide, en pratique, pour l’architecture légère comme cible réaliste du projet, ou pour un enrichissement massif par génération de données synthétiques et traduction automatique supervisée.

- (b) L’écart entre D_{emp} (seuil) et D_{ext_max} (plafond) – un facteur 100 dans les deux cas, par construction de $\gamma = 10$ appliqué à un $\alpha = 0,10$ déjà présent – offre une marge de manœuvre large pour ajuster le volume réellement collecté sans risquer l’oubli catastrophique, à condition de surveiller les capacités générales du modèle (raisonnement, connaissances en français) au cours de l’entraînement, par exemple par une batterie d’évaluations de régression déclenchée à intervalles réguliers de tokens vus, comme le suggèrent les pratiques de rejeu documentées en Section 2.2.
- (c) Les besoins en données de SFT (quelques dizaines de milliers d’exemples pour l’architecture légère) sont d’un ordre de grandeur compatible avec une production humaine ou semi-automatisée raisonnable, en cohérence avec le résultat de Zhou et al. (2023) selon lequel la qualité de la sélection des exemples importe davantage que leur nombre brut.

7 Limites de l’étude

Ce travail présente plusieurs limites qu’il convient d’explicitier.

Absence de validation expérimentale directe des coefficients α , β , γ , μ . Contrairement à D_{ch} (Chinchilla) et à la correction proposée pour Ω , ces quatre coefficients ne sont adossés à aucune régression statistique publiée spécifique au régime qu’ils modélisent (extension linguistique, oubli catastrophique, alignement SFT). Ils reflètent une synthèse raisonnée de résultats connexes (Section 2) plutôt qu’une mesure directe. Une validation future nécessiterait de reproduire, pour le pré-entraînement continu multilingue, le type de campagne d’entraînements contrôlés menée par Hoffmann et al. (2022) pour le cas from scratch.

Calibration d’ $\Omega(N)$ sur un échantillon restreint et hétérogène. Les sept points de données du Tableau 1 proviennent de laboratoires différents, avec des choix d’architecture, de mélange de données et de budget de calcul non contrôlés, ce qui explique le R^2 modéré de la

régression (0,68) et limite la portée prédictive de l’équation (24) à un ordre de grandeur plutôt qu’à une valeur précise.

Absence de prise en compte de la qualité et de la composition des données. Le cadre proposé raisonne exclusivement en volume de tokens, sans intégrer la qualité, la diversité stylistique ou la redondance du corpus – des facteurs dont la littérature sur les lois d’échelle contraintes par les données (data-constrained scaling) montre qu’ils modulent significativement l’effet d’un volume donné (Muennighoff et al., 2023).

Spécificité du cas baoulé. Les proportions retenues (70 % langue cible / 30 % français) et l’hypothèse d’un socle logique transférable depuis le français/anglais vers le baoulé restent des choix de conception du projet plutôt que des résultats généralisables à toute paire de langues, en particulier lorsque la langue cible utilise un système d’écriture ou une morphologie très éloignés des langues sources.

8 Perspectives et travaux futurs

Trois pistes se dégagent naturellement de ce travail pour une suite de recherche.

Calibration expérimentale directe du coefficient α . La valeur $\alpha = 0,10$ retenue ici est une hypothèse de travail. Une campagne d’entraînements contrôlés – sur le modèle de celle menée par Hoffmann et al. (2022) pour Chinchilla, mais appliquée au pré-entraînement continu multilingue – consisterait à faire varier le volume de tokens de la nouvelle langue pour un ensemble de tailles de modèles, et à mesurer le point d’inflexion à partir duquel les métriques de compréhension et de génération dans la nouvelle langue cessent de s’améliorer significativement. Un tel protocole permettrait de remplacer l’heuristique actuelle par une valeur (ou une fonction de N) directement mesurée.

Modélisation de γ comme fonction décroissante de N . La tension résiduelle identifiée en Section 5.5 suggère que le coefficient de tolérance à l’oubli catastrophique décroît probablement lui aussi avec la taille du modèle, par analogie avec le comportement observé pour Ω . Sa calibration nécessiterait des données comparables à celles du Tableau 1, mais mesurées spécifiquement pour des campagnes de pré-entraînement continu multilingue à différentes échelles – des données aujourd’hui peu documentées publiquement, la plupart des études d’oubli catastrophique portant sur des modèles de 1 à 7 milliards de paramètres (Luo et al., 2025).

Application et suivi empirique sur le projet baoulé. Le cadre proposé ici reste, pour l’heure, un outil de dimensionnement a priori. Sa validation la plus directe consisterait à instrumenter l’entraînement réel du modèle de 270 millions de paramètres du Cas pratique 1 : mesurer, à intervalles réguliers de tokens baoulé vus, à la fois la progression des capacités en baoulé et la rétention des capacités en français, afin de vérifier empiriquement si les seuils D_{emp} et D_{ext_max} prédits correspondent effectivement aux points d’inflexion observés.

9 Conclusion

Ce travail a examiné la cohérence d’un cadre de dimensionnement des données d’entraînement en trois contextes – création initiale, extension linguistique continue, alignement SFT – appliqué à un projet concret d’extension d’un LLM vers le baoulé pour deux architectures cibles. L’arithmétique du cadre initial s’est révélée exacte, mais l’examen critique d’une de ses hypothèses – un facteur de sur-entraînement Ω constant – a révélé une incohérence à grande échelle : appliqué tel quel à un modèle de 70 milliards de paramètres, il prescrit un plafond de 1,4 quadrillion de tokens, très au-delà de tout corpus textuel existant. La correction proposée, une loi de puissance décroissante

$\Omega(N)$ calibrée sur sept modèles publiés, ramène ce plafond à un ordre de grandeur compatible avec les corpus documentés (11,6 trillions de tokens), sans affecter les équations du contexte d’extension linguistique qui constitue l’objectif réel du projet. Au-delà du cas d’application traité ici, cet exercice illustre une exigence méthodologique plus générale : toute constante empirique introduite dans un cadre de dimensionnement doit être testée aux deux extrémités de la plage de tailles de modèles visée, et non calibrée sur un seul point puis extrapolée sans vérification.

A Annexe : tableau étendu sur dix tailles de modèles

Le Tableau 5 applique l’ensemble du cadre – y compris le plafond $D_{scratch_max}$ corrigé par l’équation (24) – à dix tailles de modèles couvrant trois ordres de grandeur, de 100 millions à 175 milliards de paramètres, afin d’illustrer la continuité des équations au-delà des deux cas pratiques traités dans le corps de l’article. Les valeurs de $\Omega(N)$ sont calculées avec les paramètres calibrés en Section 5.3 ($\Omega_0 \approx 12\,800$, $N_0 = 270 \times 10^6$, $k \approx 0,78$).

N	D_{ch}	$\Omega(N)$	$D_{scratch_max}$ (corrigé)	D_{emp}	D_{ext_max}	D_{sft_min}	D_{sft_max}
100 M	2,0 Md	27 843	2,78 T	200 M	20 Md	2 M	10 M
270 M	5,4 Md	12 800	3,46 T	540 M	54 Md	5,4 M	27 M
500 M	10 Md	7 904	3,95 T	1,0 Md	100 Md	10 M	50 M
1 Md	20 Md	4 595	4,60 T	2,0 Md	200 Md	20 M	100 M
3 Md	60 Md	1 945	5,84 T	6,0 Md	600 Md	60 M	300 M
7 Md	140 Md	1 003	7,02 T	14 Md	1,4 T	140 M	700 M
13 Md	260 Md	618	8,03 T	26 Md	2,6 T	260 M	1,3 Md
34 Md	680 Md	291	9,90 T	68 Md	6,8 T	680 M	3,4 Md
70 Md	1,4 T	166	11,58 T	140 Md	14,0 T	1,4 Md	7,0 Md
175 Md	3,5 T	81	14,14 T	350 Md	35,0 T	3,5 Md	17,5 Md

Table 5: Application du cadre corrigé à dix tailles de modèles (Md = milliards, T = trillions). À partir de $N \approx 55$ milliards (équation (27)), on observe, par comparaison directe des colonnes D_{ext_max} et $D_{scratch_max}$, que la première dépasse la seconde – matérialisant la tension résiduelle discutée en Section 5.5.

References

- [1] Wu, T., Caccia, M., Li, Z., Li, Y.-F., Qi, G., & Haffari, G. (2024). Continual Learning of Large Language Models: A Comprehensive Survey. *ACM Computing Surveys*.
- [2] (2025). DACP: Domain-Adaptive Continual Pre-Training of Large Language Models for Phone Conversation Summarization. *arXiv preprint*, arXiv:2510.05858.
- [3] Abdin, M., Jacobs, S. A., Awan, A. A., et al. (2024). Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone. arXiv:2404.14219.
- [4] Dubey, A., Jauhri, A., Pandey, A., et al. (Meta AI) (2024). The Llama 3 Herd of Models. arXiv:2407.21783.
- [5] Gemma Team, Google DeepMind (2024). Gemma: Open Models Based on Gemini Research and Technology. arXiv:2403.08295.
- [6] Gemma Team, Google DeepMind (2024). Gemma 2: Improving Open Language Models at a Small Scale. arXiv:2408.00118.

- [7] Groeneveld, D., Beltagy, I., Walsh, P., et al. (Allen Institute for AI) (2024). OLMo: Accelerating the Science of Language Models. [arXiv:2402.00838](#).
- [8] Hoffmann, J., Borgeaud, S., Mensch, A., et al. (2022). Training Compute-Optimal Large Language Models. [arXiv:2203.15556](#).
- [9] Kaplan, J., McCandlish, S., Henighan, T., et al. (2020). Scaling Laws for Neural Language Models. [arXiv:2001.08361](#).
- [10] Ke, Z., Shao, Y., Lin, H., Konishi, T., Kim, G., & Liu, B. (2023). Continual Pre-training of Language Models. *International Conference on Learning Representations (ICLR)*.
- [11] Kirkpatrick, J., Pascanu, R., Rabinowitz, N., et al. (2017). Overcoming Catastrophic Forgetting in Neural Networks. *Proceedings of the National Academy of Sciences*, 114(13), 3521-3526.
- [12] Luo, Y., Yang, Z., et al. (2025). An Empirical Study of Catastrophic Forgetting in Large Language Models During Continual Fine-Tuning. *arXiv preprint*.
- [13] Meta AI (2024). Llama 3.2: Revolutionizing Edge AI and Vision with Open, Customizable Models. Meta AI Blog / Model Card.
- [14] Muennighoff, N., Rush, A., Barak, B., et al. (2023). Scaling Data-Constrained Language Models. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [15] Sardana, N., & Frankle, J. (2024). Beyond Chinchilla-Optimal: Accounting for Inference in Language Model Scaling Laws. [arXiv:2401.00448](#).
- [16] Touvron, H., Lavril, T., Izacard, G., et al. (2023). LLaMA: Open and Efficient Foundation Language Models. [arXiv:2302.13971](#).
- [17] Touvron, H., Martin, L., Stone, K., et al. (2023). Llama 2: Open Foundation and Fine-Tuned Chat Models. [arXiv:2307.09288](#).
- [18] Zhou, C., Liu, P., Xu, P., et al. (2023). LIMA: Less Is More for Alignment. *Advances in Neural Information Processing Systems (NeurIPS)* / [arXiv:2305.11206](#).